

★ I. Fundamentos de Series de Tiempo

¿Qué tienen en común los ciclos económicos, el cambio climático y las tendencias de búsqueda en internet? Todos ellos comparten patrones analizables mediante series de tiempo: datos ordenados secuencialmente que reflejan la evolución de un fenómeno.

Imagina que estás siguiendo el precio de una acción día tras día, o registrando la temperatura promedio de tu ciudad cada mes durante varios años. En ambos casos, los valores actuales están estrechamente vinculados a los anteriores. Esta **dependencia temporal** es lo que distingue a las series de tiempo de otros tipos de observaciones y exige técnicas específicas para su análisis.

Desempeñan un papel relevante en disciplinas tan diversas como:

- **Economía y Finanzas:** precios de acciones, tasas de interés, inflación.
- **Marketing:** ventas mensuales, tráfico web, campañas estacionales.
- **Ciencias Ambientales:** temperatura, precipitaciones, calidad del aire.
- **Medicina:** evolución de epidemias, seguimiento de signos vitales.

El estudio en esta materia cumple tres funciones esenciales:

- **Describir:** visualizar el comportamiento histórico de un fenómeno.
- **Modelar:** capturar su estructura mediante técnicas estadísticas o computacionales.
- **Predecir:** estimar valores futuros a partir de su comportamiento pasado.

Estas herramientas no solo permiten comprender el pasado, sino también anticipar el futuro, convirtiéndose en aliados fundamentales para la toma de decisiones estratégicas.

En el siguiente apartado, revisaremos los **tres elementos relevantes** que componen una serie: la **tendencia**, la **estacionalidad** y el **ruido**. Estos elementos constituyen la base para cualquier modelo de pronóstico sólido.

★ II. Componentes

La mayoría de estos registros cronológicos pueden descomponerse en tres elementos esenciales que explican su comportamiento a lo largo del tiempo. Identificarlos permite comprender la estructura interna de los registros y facilita su análisis estadístico o predictivo.

A. Tendencia

La tendencia refleja la trayectoria general del fenómeno, ya sea creciente, decreciente o estable a lo largo de períodos prolongados. Puede adoptar una forma *lineal* (como el crecimiento poblacional en condiciones estables) o *no lineal*

(como el desarrollo inicial de una empresa que crece rápidamente al principio y luego se estabiliza).

B. Estacionalidad

La estacionalidad corresponde a patrones que se repiten en intervalos fijos (como meses o estaciones), asociados a comportamientos cíclicos del entorno. Ejemplos típicos incluyen el aumento de ventas en diciembre o las bajas temperaturas en invierno. Reconocer estos patrones permite aislar su efecto sobre la serie y mejorar el análisis global.

C. Ruido o Residual

El ruido, o componente residual, incluye variaciones aleatorias que no se explican por la tendencia ni la estacionalidad y suelen deberse a factores externos no modelados o eventos inesperados. Su identificación es clave para evaluar la calidad de cualquier modelo: si el ruido es bajo, gran parte de la estructura de la serie ya ha sido explicada. No siempre es un elemento "indeseable" (ej: en finanzas, puede contener información sobre volatilidad).

III. ★ Métodos Clásicos para Analizar Series de Tiempo

Para analizar series de tiempo es necesario aplicar técnicas que permitan modelar y predecir su comportamiento. A lo largo de los años, se han desarrollado diversas metodologías, algunas más recientes y otras con una trayectoria consolidada. En este capítulo, abordaremos cinco **métodos clásicos**, ordenados de

menor a mayor complejidad, que forman la base del análisis aplicado en múltiples disciplinas:

- **A. Promedio Móvil:** Permite suavizar fluctuaciones aleatorias para destacar tendencias generales.
- **B. Descomposición Clásica:** Facilita la separación sistemática de componentes como tendencia, estacionalidad y residuales.
- **C. Filtro Hodrick-Prescott (HP):** Ayuda a identificar la tendencia a largo plazo, especialmente en contextos macroeconómicos.
- **D. ARIMA/SARIMA:** Modela relaciones temporales y permite pronosticar datos estacionarios o con estacionalidad.
- **E. Prophet:** Automatiza el análisis con múltiples estacionalidades, ideal para entornos empresariales.

¿Por qué llamarlos "clásicos"? En este contexto, el término hace referencia a métodos que:

- Se han utilizado ampliamente en análisis estadísticos reales.
- Se enseñan de forma recurrente en textos académicos reconocidos como *Forecasting: Principles and Practice* (Hyndman & Athanasopoulos) o *Time Series Analysis* (Hamilton).
- Forman parte de bibliotecas estadísticas consolidadas como `statsmodels` o `pmdarima`.

Estos métodos se valoran por su simplicidad, robustez teórica y versatilidad aplicativa.

Aclaramos que este orden no representa una jerarquía de importancia entre los métodos, sino que responde a su prevalencia según la bibliografía especializada y el uso práctico. Existen otros enfoques válidos y complementarios que también pueden explorarse según el contexto del análisis.

A lo largo del capítulo, exploraremos cómo aplicar estos métodos utilizando herramientas disponibles en bibliotecas como `statsmodels` y `pmdarima`.

A. Promedio Móvil Simple (SMA)

Este ejemplo muestra cómo el promedio móvil simple permite detectar la trayectoria general de una serie simulada, que combina tres componentes: una **tendencia lineal** (`50 + i*0.1`), una **estacionalidad sinusoidal** (`5*np.sin(i*0.1)`) y un **componente aleatorio** (`np.random.normal(0, 2)`).

Se calcula una media móvil de 7 días mediante `rolling(window=7).mean()`, que atenúa las fluctuaciones filtrando el ruido. Por ejemplo, el valor del día 10 se obtiene promediando los valores de cierre de los días 4 al 10. Esta técnica introduce un **desfase aproximado de 3 días**, lo que la hace inadecuada para *predicciones en tiempo real*, ya que solo refleja *tendencias pasadas*. Ejemplo: En un mercado volátil, el SMA de 7 días confirmaría una tendencia alcista solo después de que los precios ya hayan subido varios días. Para pronósticos más robustos, se requieren enfoques como **ARIMA o Prophet**.

En el gráfico generado se observan dos curvas: una azul (valores diarios simulados) y otra roja (promedio móvil). El contraste entre ambas permite visualizar cómo la suavización ayuda a destacar la dirección general del fenómeno, reduciendo el impacto de la variabilidad aleatoria. **Nótese que la curva roja (SMA) se desplaza a la derecha de la azul en el gráfico:** esto refleja el **desfase temporal** inherente al método. Por ejemplo, si la serie original sube abruptamente el día 10, el promedio móvil solo alcanzará ese nivel alrededor del día 13. Este retraso es inevitable al usar valores pasados para calcular el promedio, y es clave considerarlo en análisis donde la oportunidad es crítica (ej: trading algorítmico).

Este método es útil como primera aproximación en el análisis exploratorio, especialmente cuando los datos presentan ruido o estacionalidad leve. También es común en entornos financieros, como parte de estrategias de entrada y salida basadas en cruces de líneas.

Alternativa técnica: si se desea reducir el desfase, se puede usar `rolling(window=7, center=True)`. Esto centra la ventana, pero genera valores `NaN` en los extremos, lo cual puede ser problemático en análisis en tiempo real o series cortas.

```
In [22]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt


# Crear datos de ejemplo (simulando precio de acción diario)
df = pd.DataFrame({'fecha': dates, 'precio': values}).set_index('fecha')
dates = pd.date_range(start='2024-01-01', end='2024-12-31', freq='D')
values=[50+i*0.1+5*np.sin(i*0.1)+np.random.normal(0, 2) for i in range(len(dates))]

# Calcular el promedio móvil de 7 días
df['SMA_7'] = df['precio'].rolling(window=7).mean()

# Graficar la serie original y el promedio móvil
```

```
plt.figure(figsize=(12, 6))
plt.plot(df.index, df['precio'], label='Precio Diario')
plt.plot(df.index, df['SMA_7'], label='Promedio Móvil (7 días)', color='red')
plt.title('Precio de Acción Diario vs. Promedio Móvil')
plt.xlabel('Fecha')
plt.ylabel('Precio')
plt.legend()
plt.grid(True)

# Añadir anotación para ilustrar el desfase (ejemplo: día 20)
plt.axvline(x=df.index[20], color='gray', linestyle='--', alpha=0.5)
plt.text(df.index[20], df['precio'].max() * 0.9, 'Desfase ≈3 días',
        ha='center', color='gray', bbox=dict(facecolor='white', alpha=0.8))
plt.show()
```



B. Descomposición Clásica

Esta técnica permite separar una serie temporal en tres partes fundamentales: **tendencia** (T_t), **estacionalidad** (S_t) y **ruido** (R_t). Se utiliza principalmente cuando se desea entender el comportamiento interno de una serie con patrones regulares, como las ventas mensuales, la temperatura estacional o la demanda energética.

- **Modelo aditivo:** $Y_t = T_t + S_t + R_t$ (cuando la estacionalidad tiene magnitud constante)

- **Modelo multiplicativo:** $Y_t = T_t \times S_t \times R_t$ (cuando la estacionalidad varía proporcionalmente al nivel de la serie)

Implementación en Python:

```
from statsmodels.tsa.seasonal import  
seasonal_decompose  
  
result = seasonal_decompose(serie,  
model='additive', period=12)
```

Requisitos para una descomposición confiable:

1. Estacionalidad fija y conocida (por ejemplo, un ciclo anual).
2. Tendencia suave y sin rupturas abruptas.
3. Residuales sin patrón visible (aleatorios), lo que puede verificarse con la función `plot_acf` de statsmodels.

Limitaciones: No funciona bien si la estacionalidad cambia a lo largo del tiempo o si hay valores atípicos severos. En esos casos, es preferible usar **STL** o **Prophet**. Este método funciona bien en series con estacionalidad fija, pero puede ser limitado en contextos donde la periodicidad varía.

Ejemplo: A continuación, aplicaremos esta técnica en Python y analizaremos el gráfico resultante para entender mejor cómo se separan los componentes de una serie sintética.

Razón para usar este ejemplo: Se eligió una serie diseñada específicamente para cumplir con los requisitos del modelo:

- Tendencia definida por crecimiento lineal ($50 + i \times 0.5$).
- Estacionalidad perfecta: patrón repetido de +10 durante los primeros tres meses de cada año.

– Ruido moderado: generado por `np.random.normal(0, 3)`.


Este caso ilustrativo facilita la separación clara de cada componente, facilitando su interpretación visual y estadística.

Nota: Las gráficas generadas por la función `seasonal_decompose` aparecerán en inglés por defecto. Cambiar los títulos al español requiere personalización manual de cada subgráfico.

```
In [23]: from statsmodels.tsa.seasonal import seasonal_decompose
import matplotlib.pyplot as plt

# Datos de ejemplo (reemplazar con tu serie)
data = [50 + i*0.5 + 10 * ((i % 12) < 3) + np.random.normal(0, 3) for i in range(100)]

# Descomposición aditiva
result = seasonal_decompose(data, model='additive', period=12) # Periodo estacional
result.plot()
plt.show()
```



C. Filtro Hodrick-Prescott

El Filtro de Hodrick-Prescott (HP) es una técnica clásica utilizada para separar una serie de tiempo en dos componentes principales: una **tendencia suavizada** de largo plazo (T_t) y un **ciclo** (C_t) que captura fluctuaciones de corto plazo. Su uso es muy frecuente en macroeconomía, especialmente para analizar el crecimiento potencial del PIB y la brecha cíclica.

A diferencia de métodos como el promedio móvil o la descomposición clásica, el filtro HP no requiere que la estacionalidad sea fija ni que los datos estén previamente ajustados. Su fortaleza radica en la capacidad de aislar la tendencia sin eliminar la variabilidad cíclica relevante.

Ejemplo ilustrativo: En el siguiente caso simulado, se genera una serie compuesta por:

- *Tendencia cuadrática:* $0.1 \cdot (t - 50)^2$, que representa un crecimiento no lineal.
- *Ciclo sinusoidal:* $10 \cdot \sin(2\pi t/20)$, para modelar oscilaciones económicas regulares.
- *Ruido aleatorio:* $N(0, 2)$, que aporta variabilidad.

Al aplicar HP, se obtiene una curva roja que representa la tendencia **estimada** y una línea verde con las fluctuaciones cíclicas. La separación es efectiva porque la serie fue construida para cumplir con las condiciones ideales del método.

Este método no es adecuado si los ciclos no son regulares o si la estacionalidad **cambia** en el tiempo. Tampoco permite

predicción directa, ya que es puramente descriptivo.

Gráficamente: El ejemplo muestra cómo la técnica HP separa el crecimiento estructural (tendencia de largo plazo) de las fluctuaciones temporales (componente cíclico), incluso con ruido presente.


Esta herramienta es un estándar en estudios macroeconómicos y resulta útil para descomponer series cuando se conoce la frecuencia de los ciclos. En la siguiente sección, se presentará el código completo en Python para replicar este caso con datos simulados.

```
In [24]: # Ejemplo completo con gráfico (para incluir en la sección)
import numpy as np
import matplotlib.pyplot as plt
from statsmodels.tsa.filters.hp_filter import hpfilter

# 1. Generar datos sintéticos (tendencia cuadrática + ciclo)
np.random.seed(42)
t = np.arange(100)
tendencia = 0.1*(t - 50)**2
ciclo = 10*np.sin(2*np.pi*t/20) # Ciclo cada 20 periodos
ruido = np.random.normal(0, 2, 100)
Y = tendencia + ciclo + ruido

# 2. Aplicar filtro HP
tendencia_HP, ciclo_HP = hpfilter(Y, lamb=1600) # λ para datos trimestrales

# 3. Graficar
plt.figure(figsize=(12, 6))
plt.plot(Y, label='Serie Original', color='blue', alpha=0.5)
plt.plot(tendencia_HP, label='Tendencia (HP)', color='red', linewidth=2)
plt.plot(ciclo_HP, label='Ciclo (HP)', color='green', linestyle='--')
plt.title('Descomposición con Filtro Hodrick-Prescott')
plt.xlabel('Tiempo')
plt.ylabel('Valor')
plt.legend()
plt.grid(True)
plt.show()
```



Nota Técnica: Explicación de la Fórmula del Filtro Hodrick-Prescott

Fórmula matemática:

$$\min_{T_t} \left(\sum_{t=1}^T (Y_t - T_t)^2 + \lambda \sum_{t=2}^{T-1} [(T_{t+1} - T_t) - (T_t - T_{t-1})]^2 \right)$$

Donde:

- Y_t : Valor observado de la serie en el tiempo t (los datos originales).
- T_t : Componente de tendencia en el tiempo t (lo que el filtro estima).
- T_{t-1} , T_{t+1} : Tendencia en los periodos adyacentes ($t - 1$ y $t + 1$).

Interpretación y propósito:

El desarrollo matemático completo del filtro Hodrick-Prescott es más extenso y no será tratado aquí. Sin embargo,

a continuación se presenta una interpretación intuitiva de su funcionamiento y propósito. Esta expresión busca minimizar dos objetivos al mismo tiempo:

- **Ajuste a los datos:** El primer término penaliza grandes diferencias entre la serie original Y_t y la tendencia T_t , forzando que la curva ajustada siga de cerca los datos observados.
- **Suavidad de la tendencia:** El segundo término penaliza cambios abruptos en la tasa de crecimiento de la tendencia. Es decir, desalienta aceleraciones bruscas en el movimiento de T_t .

El parámetro λ controla el equilibrio entre estos dos objetivos:

- Si λ es bajo $\rightarrow$ se ajusta más a los datos (menos suavizado).
- Si λ es alto $\rightarrow$ se obtiene una tendencia más lisa (más suavizado).

Ejemplo numérico (simplificado):

Dada una serie $Y = [10, 12, 15, 14, 18]$ y un valor $\lambda = 100$, el filtro HP podría estimar una tendencia como $T = [10.2, 11.8, 14.1, 14.9, 17.5]$, que:

- Se aproxima a los datos originales sin imitarlos exactamente.
- Evita giros bruscos, generando una trayectoria suave de crecimiento.

Aplicaciones típicas:

- En economía: Separar el PIB en su componente estructural (tendencia) y la brecha del producto (ciclo).
- En finanzas: Extraer tendencias de largo plazo en precios o rentabilidades.

Advertencia: El filtro HP no garantiza resultados válidos si los datos no presentan ciclos regulares o si se elige un valor inadecuado de λ . Siempre se recomienda inspección visual y análisis de sensibilidad.